Clasificación del desempeño académico utilizando modelos de Machine Learning y Deep Learning

Alumna: Rebeca Cuan Corral

Universidad Autónoma del Estado de Morelos

Proyecto final del diplomado en ciencia de datos con Python

Profesor: Dr. Mauricio Toledo

03 de agosto de 2024

Clasificación del desempeño académico utilizando modelos de Machine Learning y Deep Learning

Identificación del problema:
¿Cómo predecir el desempeño académico de los estudiantes de preparatoria en base con los datos demográficos, los hábitos de estudio, la participación de los padres y las actividades extracurriculares?

Objetivo:
Seleccionar el modelo de *Machine Learning* más preciso (*accuracy*) para clasificar el desempeño estudiantil dentro de los siguientes algoritmos:

- Logistic Regression.
- Random Forest.
- Support Vector Machine (SVM).
- Decision Tree.
- Multilayer Perceptron(MLP).

Metodología:
A continuación, se describen las etapas del proyecto de Machine Learning.

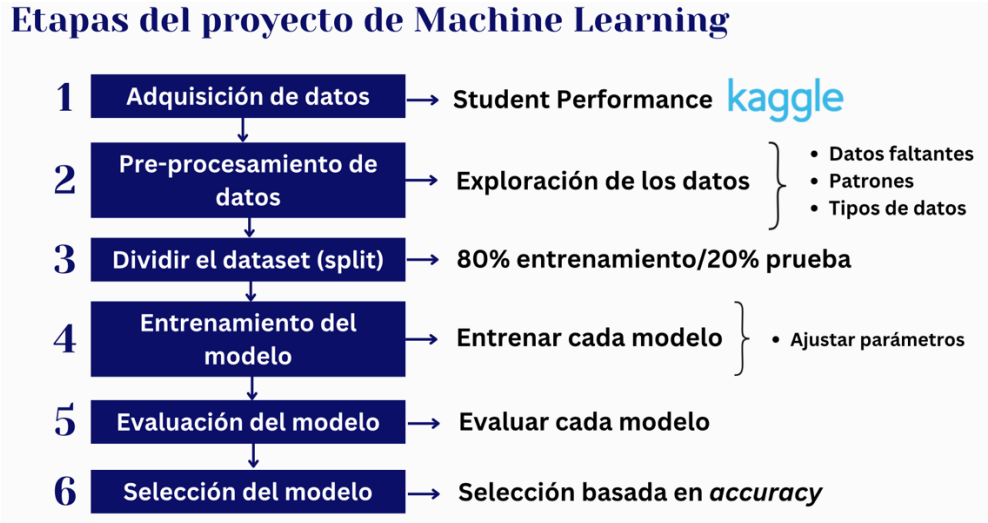

Los datos utilizados se tomaron de Kaggle (Rabie El Kharoua, 2024).
En la etapa 3 se dividen los datos en una proporción 80% (entrenamiento) / 20% (prueba).
Los datos se escalaron utilizando el módulo *StandardScaler*.

Resultados:
A continuación, se describirán los resultados de cada uno de los modelos de Machine Learning.

Regresión Logística

Se entrenaron los siguientes escenarios:

1. Regresión Logística con los parámetros por defecto.
2. Regresión Logística con *Polinomial Features.*
3. Regresión Logística con los mejores parámetros resultandtes de la busqueda utilizando *GridsearchCV.*
4. Regresión Logística con los mejores parámetros resultantes de la busqueda utilizando *GridsearchCV,* después de aplicar Feature Selection usando *SelectKBest.*

Los resultados son los siguientes:

#Modelo	Parámetros	Accuracy
1	Default	71.82%
2	PolynomialFeatures(2,include_bias=False) LogisticRegression(max_iter=100000, random_state=42, solver='saga')	70.56%
3	param_grid = {'C': [0.1, 1, 10], 'penalty': ['l1', 'l2'], 'max_iter': [3000], 'solver': ['saga']} LogisticRegression(max_iter=3000, random_state=42, solver='saga', C=1, penalty='l1')	72.23%
4	SelectKBest(chi2, k=14) LogisticRegression(max_iter=3000, random_state=42, solver='saga', C=1, penalty='l1')	73.7%

A continuación, se presentan los coeficientes para el escenario de Regresión Logística número 4. En este escenario se hizo una selección de atributos utilizando el módulo *SelectKBest.*

```
# Ver los coeficientes
odds = np.exp(clf_lr_selected.coef_[0])
pd.DataFrame(odds,
             selector.get_feature_names_out(),
             columns=['coef'])
```

	coef
StudyTimeWeekly	1.080722
Absences	0.874932
Ethnicity_2	1.538189
Ethnicity_3	0.851647
ParentalEducation_4	1.000000
Tutoring_1	2.510916
ParentalSupport_1	1.000000
ParentalSupport_2	0.990683
ParentalSupport_3	3.211383
ParentalSupport_4	5.649132
Extracurricular_1	1.589320
Sports_1	1.643693
Music_1	1.221400
Volunteering_1	1.000000

Respecto a los coeficientes de Regresión Logística que aparecen en la imagen anterior, podemos decir lo siguiente:

- La variable faltas (absences) reducen la probabilidad de pertenecia a la calificación "A" (coeficiente menor que 1).
- El ParentSupport3 y ParentSupport4 (Alto y Muy Allto, respectivamente) aumentan la probabilidad de obtener una clase "A" (coeficiente mayor que 1).

Los siguientes modelos se entrenarán con el dataset resultante de utilizar SelectKBest=14.

Decision Trees
Se entrenaron los siguientes escenarios:

1. Decision Trees con los parámetros por defecto.
2. Decision Trees con los mejores parámetros resultantes de la búsqueda utilizando *GridSearchCV.*

Los resultados son los siguientes:

#Modelo	Parámetros	Accuracy
1	Default	62.21%
2	DecisionTreeClassifier(max_depth=9, criterion='gini', ccp_alpha=0.001, max_features=None)	67.43%

Random Forest
Se entrenaron los siguientes escenarios:

1. Random Forest con los parámetros por defecto.
2. Random Forest con los mejores parámetros resultandtes de la búsqueda utilizando *GridSearchCV.*

Los resultados son los siguientes:

# Modelo	Parámetros	Accuracy
1	Default	69.7%
2	RandomForestClassifier(random_state=42, max_depth=13)	70.6%

Support Vector Machine (SVM)
Se entrenaron los siguientes escenarios:

1. SVM con los parámetros por defecto.
2. SVM con los mejores parámetros resultantes de la búsqueda utilizando *GridSearchCV.*

Los resultados son los siguientes:

# Modelo	Parámetros	Accuracy
1	Default	76.61%
2	SVC(kernel='rbf',C=10, gamma=0.01,random_state=42)	74.95%

Multi-Layer Perceptron (MLP)
Se entrenaron los siguientes escenarios:

1. MLP con 1 capa oculta.

Los resultados son los siguientes:

# Modelo	Parámetros	Accuracy
1	model = Sequential() model.add(Dense(16, activation='relu', input_dim=14)) # model.add(Dense(32, activation='relu')) model.add(Dense(5, activation='softmax'))	72.23%

Resumen general

Modelo	Accuracy
Regresión Logística	73.7%
Decision Trees	67.43%
Random Forest	70.1%
SVM	74.95% - 76.61%
MLP	72.23%

Conclusiones

- El modelo de clasificación más preciso es el de SVM con un accuracy de 74.95%.
- El modelo más interpretable es el Logistic Regression con un accuracy de 73.7%, tres puntos porcentuales menos que el mejor modelo encontrado (SVM).
- La decisión de qué modelo se va a elegir va a depender si el **usuario final** prefiere **interpretabilidad** o mejor resultado.

Referencias

Rabie El Kharoua. (2024). 📚 Students Performance Dataset 📚 [Data set]. Kaggle. https://doi.org/10.34740/KAGGLE/DS/5195702